


A decorative graphic on the left side of the slide consists of a grid of colored squares. The top row has one teal square. The second row has an orange square followed by a brown square. The third row has an orange square, a teal square, and a light brown square. The bottom row has a light brown square, an orange square, an orange square, and a brown square.


# Решающие деревья

**Повторение**


# Многоклассовая классификация



# One-vs-All (One-vs-Rest)



# All-vs-All (One-vs-One)



# Доля ошибок

- Функционал ошибки — доля ошибок (error rate)

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i]$$

- Нередко измеряют долю верных ответов (accuracy):

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) = y_i]$$

- Подходит для многоклассового случая!

# Общие подходы

## Микро-усреднение

Вычисляем  $TP_k, FP_k, FN_k, TN_k$  для каждого класса

Суммируем по всем классам, получаем TP, FP, FN, TN

Подставляем их в формулу для precision/recall/...

$$\text{Precision} = \frac{\sum_k TP_k}{\sum_k TP_k + \sum_k FP_k}$$

## Макро-усреднение

Вычисляем нужную метрику для каждого класса (например,  $\text{precision}_1, \dots, \text{precision}_K$ )

Усредняем по всем классам

$$\text{Precision} = \frac{\sum_k \text{Precision}_k}{K}$$

# Label encoding

- Значения признака «район»:  $U = \{u_1, \dots, u_m\}$
- Новые признаки вместо  $x_j$ : каждая категория заменяется числом от 0 до  $m-1$
- **Label encoding**



# One-hot encoding

- Значения признака «район»:  $U = \{u_1, \dots, u_m\}$
- Новые признаки вместо  $x_j$ :  $[x_j = u_1], \dots, [x_j = u_m]$
- **One-hot encoding**

# Mean encoding

- Не хотим сильно увеличивать размер выборки только из-за кодирования признаков
- Хотим передать информацию о целевой переменной в данные — это может позволить ускорить обучение
- **Mean encoding (target encoding)**

# Mean encoding

- Задача регрессии
- Заменим категориальный признак на числовой:

$$\widetilde{x_{ij}} = \frac{\text{target}(j, x_{ij})}{\text{count}(j, x_{ij})}$$

# Mean encoding

- Задача классификации
- Заменим категориальный признак на  $K$  числовых:

$$\widetilde{x}_{ij} = \left( \frac{\text{target}_1(j, x_{ij})}{\text{count}(j, x_{ij})}, \dots, \frac{\text{target}_K(j, x_{ij})}{\text{count}(j, x_{ij})} \right)$$

# Mean encoding

- В отличие от label encoding, где мы кодируем признак случайными категориями, тут намного больше смысла
- Однако, раз мы добавляем информацию о целевой переменной в данные, то можно легко переобучиться

# Борьба с переобучением в счётчиках

- Mean encoding позволяет заменить категориальный признак на один числовой
- Могут привести к переобучению
- Можно бороться с ним через добавление шума, априорных значений или кросс-валидацию

**Как делать нелинейные  
модели?**

# Предсказание стоимости квартиры

- Признаки: площадь, этаж, расстояние до метро и т.д.
- Целевая переменная: рыночная стоимость квартиры




# Предсказание стоимости квартиры

- Линейная модель:

$$a(x) = w_0 + w_1 * (\text{площадь}) + w_2 * (\text{этаж}) \\ + w_3 * (\text{расстояние до метро}) + \dots$$

- Вряд ли признаки линейно связаны с целевой переменной



# Предсказание стоимости квартиры

- Линейная модель:

$$a(x) = w_0 + w_1 * (\text{площадь}) + w_2 * (\text{этаж}) \\ + w_3 * (\text{расстояние до метро}) + \dots$$

- Вряд ли признаки не связаны между собой

# Предсказание стоимости квартиры

- Линейная модель с полиномиальными признаками:

$$\begin{aligned} a(x) = & w_0 + w_1 * (\text{площадь}) + w_2 * (\text{этаж}) \\ & + w_3 * (\text{расстояние до метро}) + w_4 * (\text{площадь})^2 \\ & + w_5 * (\text{этаж})^2 + w_6 * (\text{расстояние до метро})^2 \\ & + w_7 * (\text{площадь}) * (\text{этаж}) + \dots \end{aligned}$$

# Предсказание стоимости квартиры

- Линейная модель с полиномиальными признаками:

$$\begin{aligned} a(x) = & w_0 + w_1 * (\text{площадь}) + w_2 * (\text{этаж}) \\ & + w_3 * (\text{расстояние до метро}) + w_4 * (\text{площадь})^2 \\ & + w_5 * (\text{этаж})^2 + w_6 * (\text{расстояние до метро})^2 \\ & + w_7 * (\text{площадь}) * (\text{этаж}) + \dots \end{aligned}$$


- Может быть сложно интерпретировать модель
- Что такое  $(\text{расстояние до метро}) * (\text{этаж})^2$ ?

# Предсказание стоимости квартиры

- Допустим, изначально имеем 10 признаков
- Полиномиальных степени 2: 55
- Полиномиальных степени 3: 220
- Полиномиальных степени 4: 715

# Предсказание стоимости квартиры

- Линейная модель с полиномиальными признаками:



# Предсказание стоимости квартиры

- Линейная модель с полиномиальными признаками:

$$a(x) = w_0 + w_1 * [30 < \text{площадь} < 50]$$

$$+ w_2 * [50 < \text{площадь} < 80] + \dots$$

$$+ w_{20} * [2 < \text{этаж} < 5] + \dots$$

$$+ w_{100} * [30 < \text{площадь} < 50][2 < \text{этаж} < 5] + \dots$$

- Признаки интерпретируются куда лучше:  $[30 < \text{площадь} < 50][2 < \text{этаж} < 5][100 < \text{расстояние до метро} < 500]$
- Но их станет ещё больше!


# Решающие деревья




# Логические правила

- $[30 < \text{площадь} < 50][2 < \text{этаж} < 5][500 < \text{расстояние до метро} < 1000]$
- Легко объяснить, как работают
- Находят нелинейные закономерности
- Нужно как-то искать хорошие логические правила
- Нужно уметь составлять модели из логических правил

# Решающее дерево

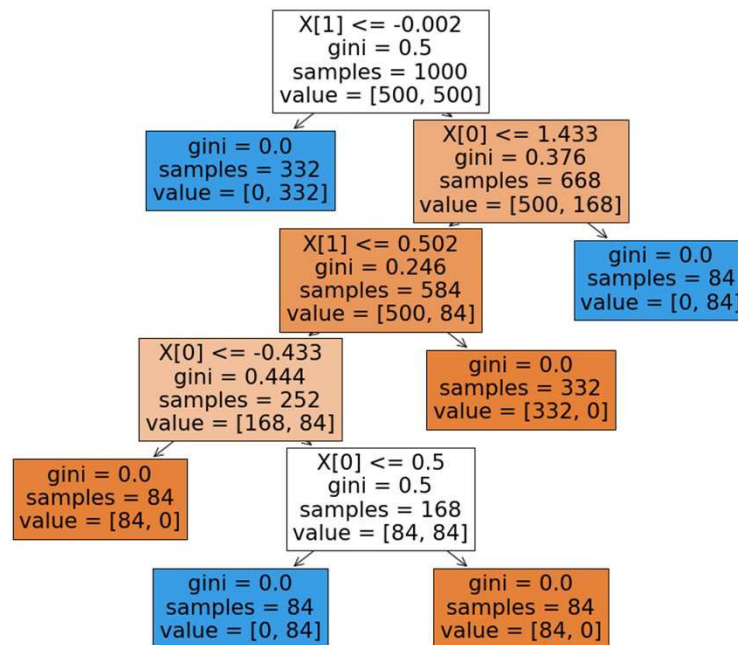



# Решающее дерево

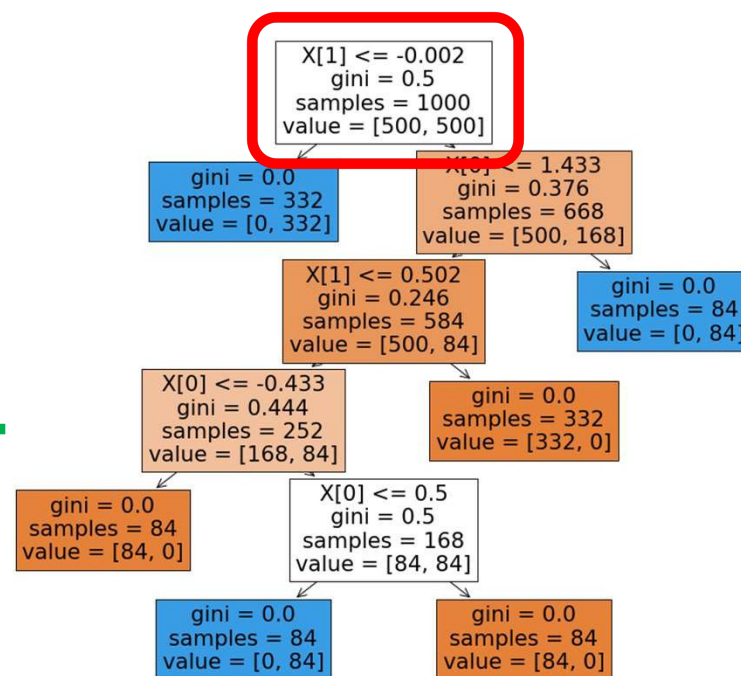



- Внутренние вершины: предикаты  $[x_j < t]$
- Листья: прогнозы  $c \in \mathbb{Y}$

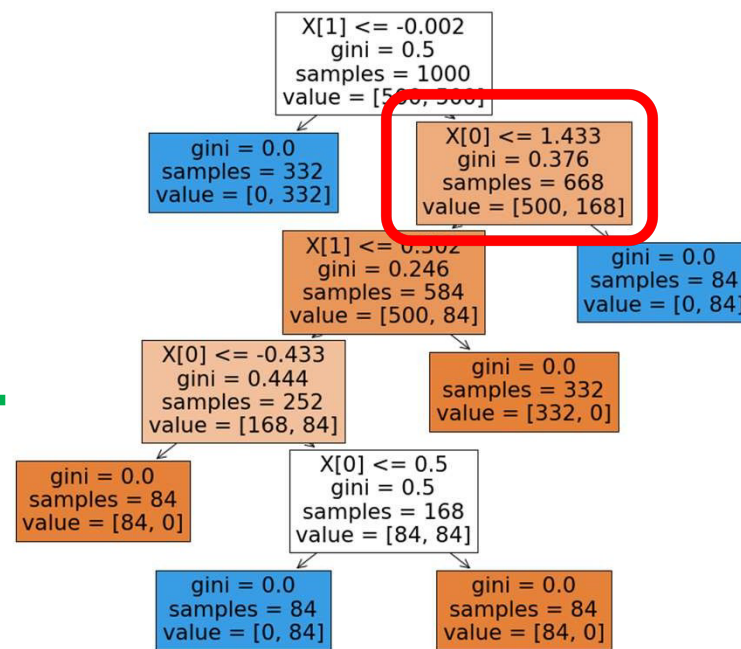

# Решающее дерево



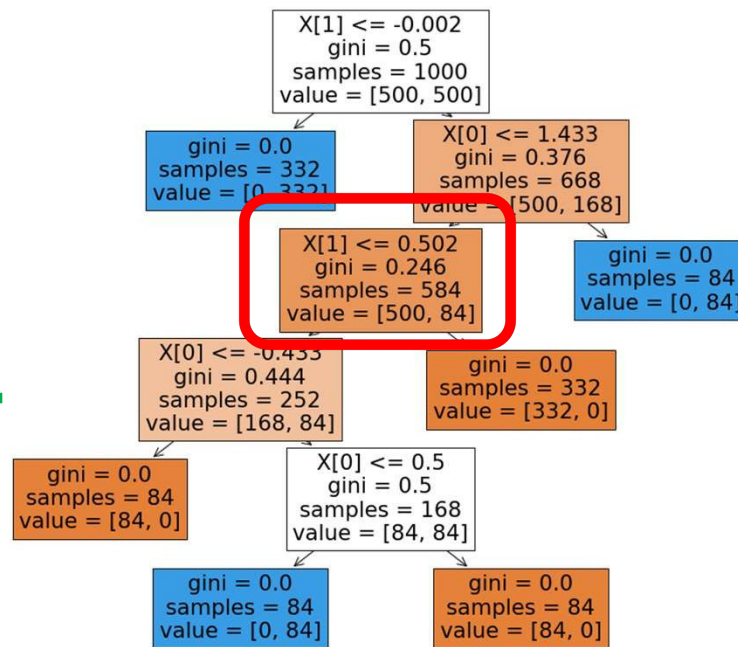

# Решающее дерево



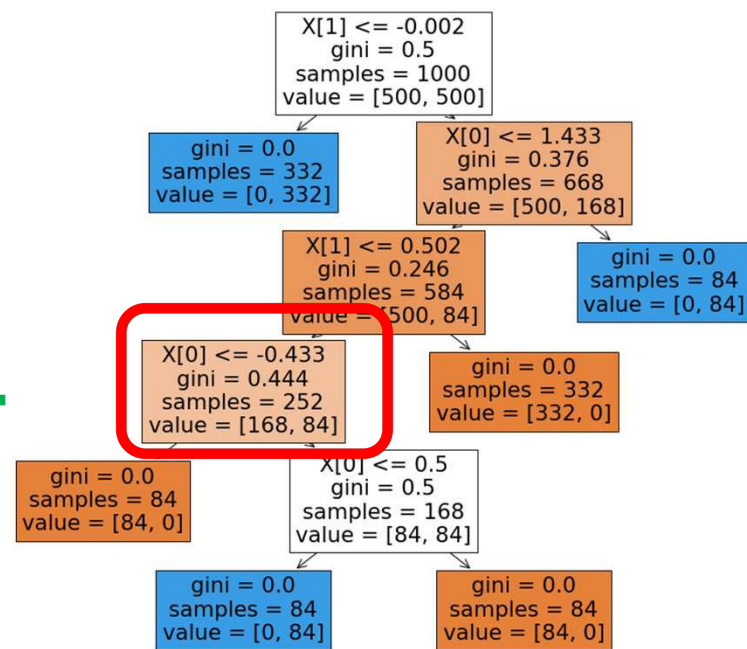

# Решающее дерево



# Решающее дерево

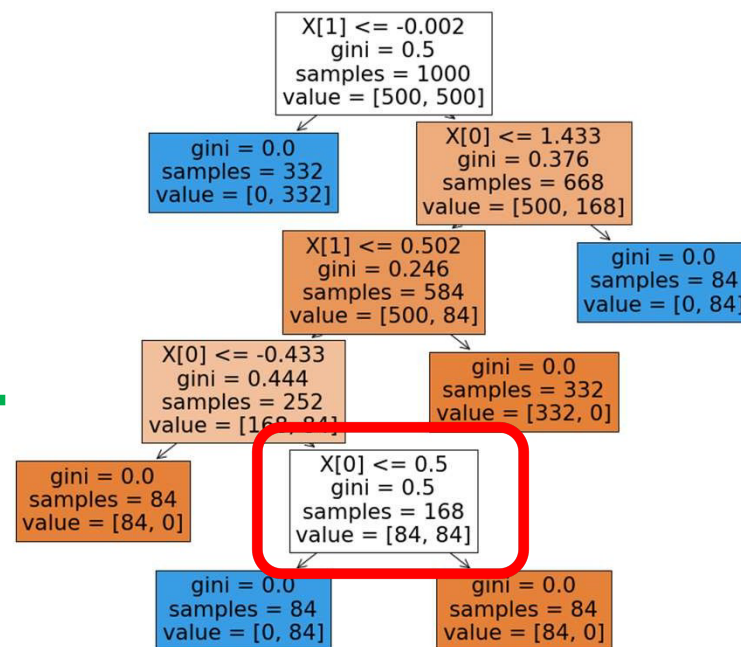



# Решающее дерево

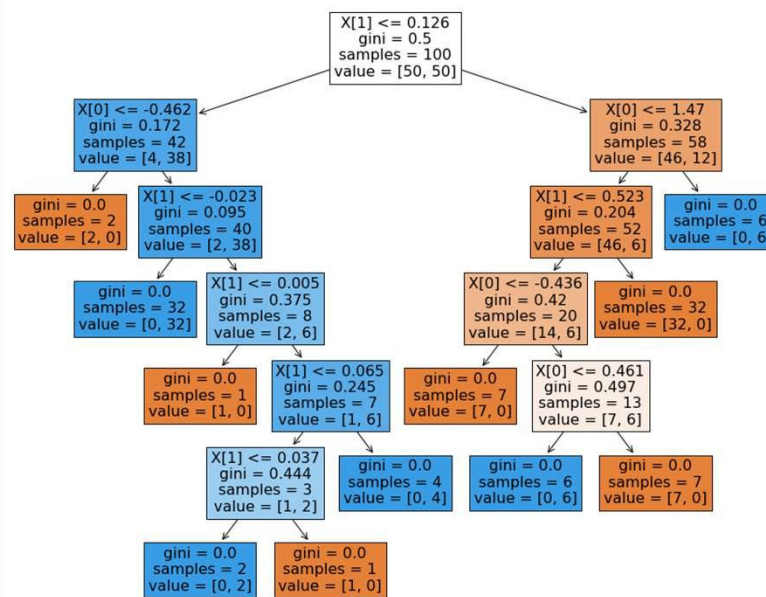





# Решающее дерево



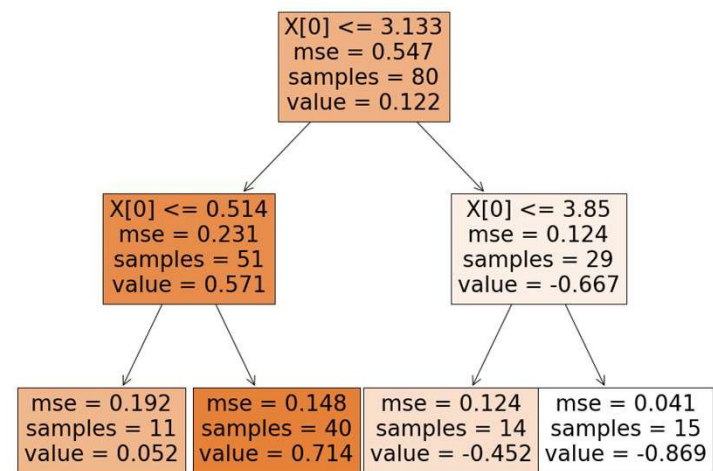

# Решающее дерево



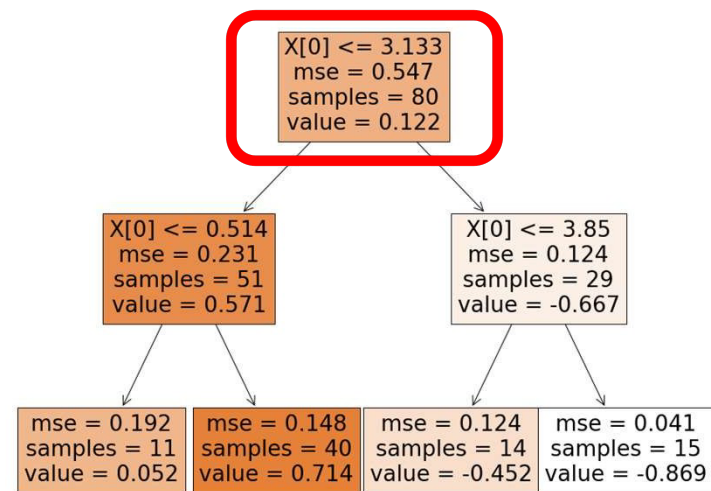

# Сложность дерева

- Решающее дерево можно строить до тех пор, пока каждый лист не будет соответствовать ровно одному объекту
- Деревом можно идеально разделить любую выборку!
- Если только нет объектов с одинаковыми признаками, но разными ответами

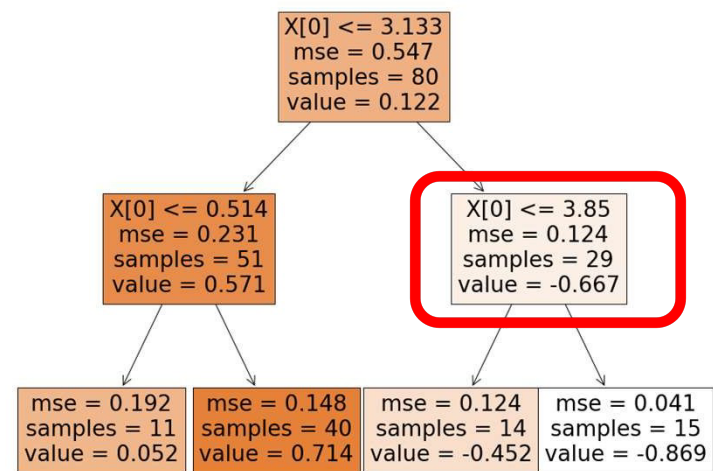

# Решающее дерево для регрессии



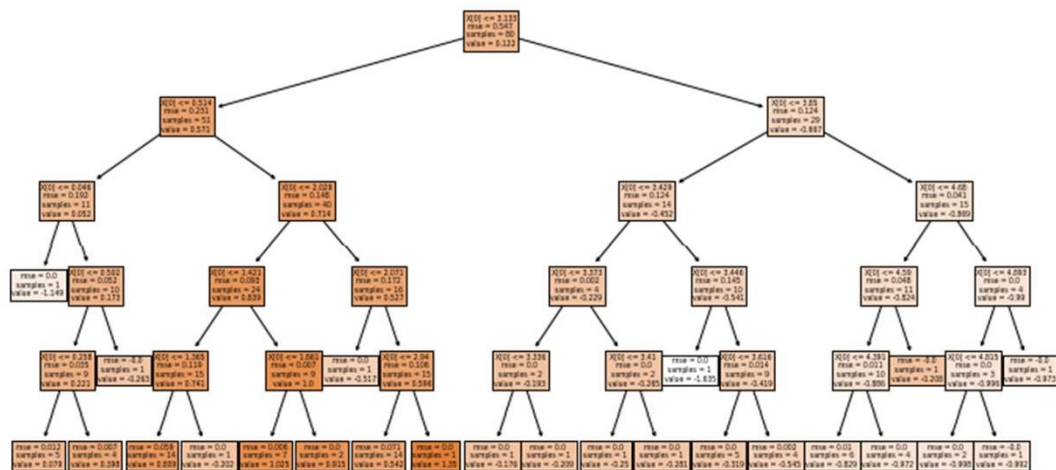
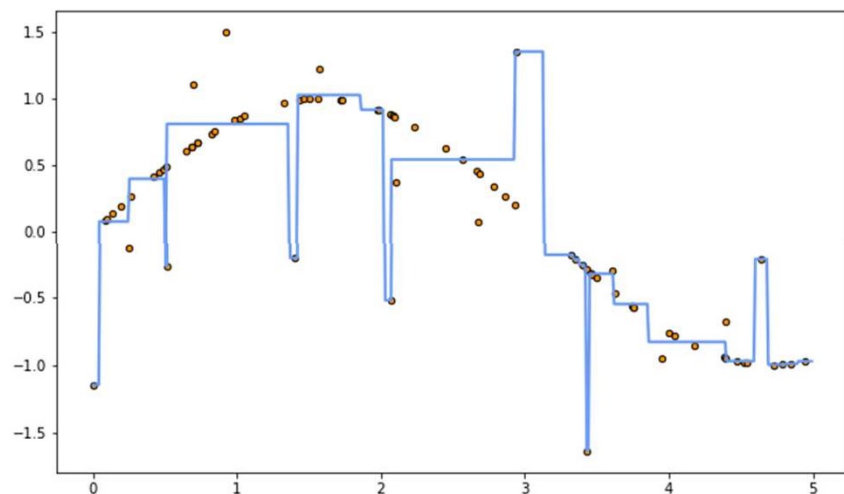
# Решающее дерево для регрессии




# Решающее дерево для регрессии



# Решающее дерево для регрессии



# Решающее дерево



- Внутренние вершины: предикаты  $[x_j < t]$
- Листья: прогнозы  $c \in \mathbb{Y}$



# Предикаты

- Порог на признак  $[x_j < t]$  — не единственный вариант
- Предикат с линейной моделью:  $[\langle w, x \rangle < t]$
- Предикат с метрикой:  $[\rho(x, x_0) < t]$
- И много других вариантов
- Но даже с простейшим предикатом можно строить очень сложные модели

# Прогнозы в листьях

- Наш выбор: константные прогнозы  $c_v \in \mathbb{Y}$
- Регрессия:

$$c_v = \frac{1}{|R_v|} \sum_{(x_i, y_i) \in R_v} y_i$$

- Классификация:

$$c_v = \arg \max_{k \in \mathbb{Y}} \sum_{(x_i, y_i) \in R_v} [y_i = k]$$

# Прогнозы в листьях

- Наш выбор: константные прогнозы  $c_v \in \mathbb{Y}$
- Классификация и вероятности классов:

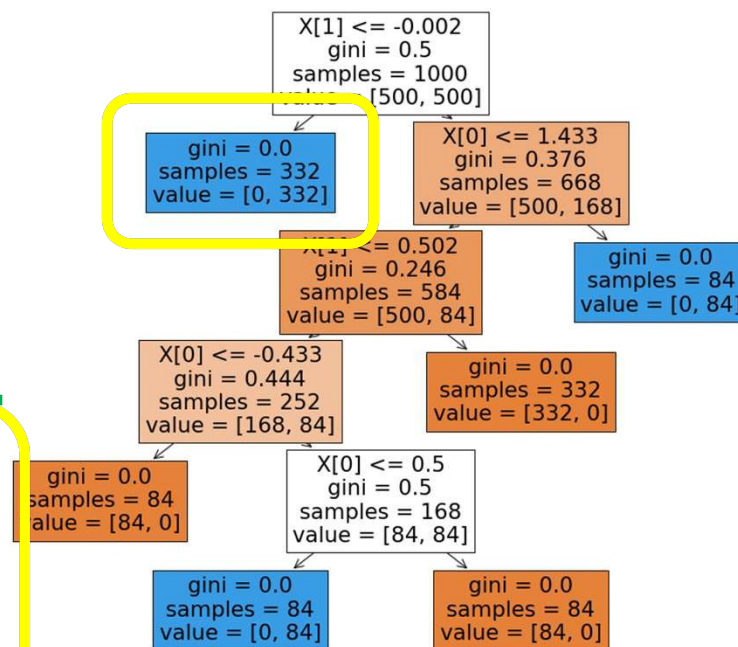

$$c_{vk} = \frac{1}{|R_v|} \sum_{(x_i, y_i) \in R_v} [y_i = k]$$

# Прогнозы в листьях

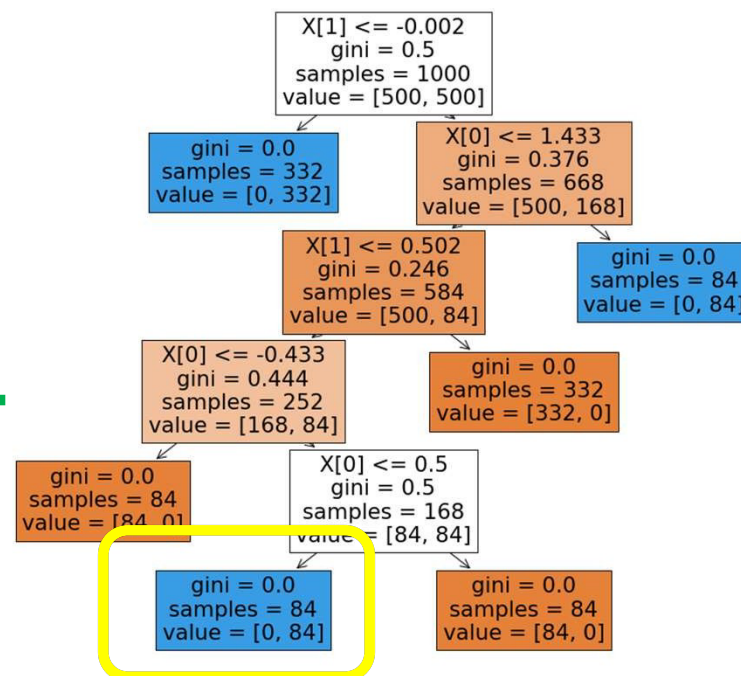

- Можно усложнять листья
- Например:

$$c_v(x) = \langle w_v, x \rangle$$

# Решающее дерево



# Решающее дерево



# Формула для дерева

- Дерево разбивает признаковое пространство на области  $R_1, \dots, R_J$
- Каждая область  $R_j$  соответствует листу
- В области  $R_j$  прогноз  $c_j$  константный

$$a(x) = \sum_{j=1}^J c_j [x \in R_j]$$

# Формула для дерева

$$a(x) = \sum_{j=1}^J c_j [x \in R_j]$$

- Решающее дерево находит хорошие новые признаки
- Над этими признаками подбирает линейную модель




**Как выбирать предикаты?**

# Жадное построение


- Разберёмся на примере
- Начнём с задачи классификации

# Жадное построение




- Как разбить вершину?


# Жадное построение




# Жадное построение




# Жадное построение



# Жадное построение




# Жадное построение






# Как сравнить разбиения?





или




# Энтропия

- Мера неопределённости распределения




# Энтропия

- Мера неопределённости распределения



Высокая энтропия



Низкая энтропия

# Энтропия


- Дискретное распределение
- Принимает  $n$  значений с вероятностями  $p_1, \dots, p_n$
- Энтропия:

$$H(p_1, \dots, p_n) = - \sum_{i=1}^n p_i \log p_i$$


# Энтропия

- $(0.2, 0.2, 0.2, 0.2, 0.2)$
- $H = 1.60944 \dots$
- $(0.9, 0.05, 0.05, 0, 0)$
- $H = 0.394398 \dots$
- $(0, 0, 0, 1, 0)$
- $H = 0$

# Как сравнить разбиения?



- $(0.5, 0.5, 0)$  и  $(0, 0, 1)$
- $H = 0.693 + 0 = 0.693$



- $(0.33, 0.33, 0.33)$  и  $(0.33, 0.33, 0.33)$
- $H = 1.09 + 1.09 = 2.18$

# Энтропия

$$H(p_1, \dots, p_K) = - \sum_{i=1}^K p_i \log_2 p_i$$

- Характеристика «хаотичности» вершины
- Impurity


# Критерий Джини

$$H(p_1, \dots, p_K) = \sum_{i=1}^K p_i (1 - p_i)$$

- Вероятность ошибки случайного классификатора, который выдаёт класс  $k$  с вероятностью  $p_k$




# Критерии качества вершины





# Критерий информативности

- Как понять, какой предикат лучше?
- Сравнить хаотичность в исходной вершине и в двух дочерних!




против





# Критерий информативности

- Как понять, какой предикат лучше?
- Сравнить хаотичность в исходной вершине и в двух дочерних!



против



# Критерий информативности

- Как понять, какой предикат лучше?
- Сравнить хаотичность в исходной вершине и в двух дочерних!

$$Q(R, j, t) = H(R) - H(R_\ell) - H(R_r) \rightarrow \max_{j, t}$$

# Критерий информативности

- Как понять, какой предикат лучше?
- Сравнить хаотичность в исходной вершине и в двух дочерних!


$$Q(R, j, t) = H(R) - H(R_\ell) - H(R_r) \rightarrow \max_{j,t}$$

- Или так:


$$Q(R, j, t) = H(R_\ell) + H(R_r) \rightarrow \min_{j,t}$$

- (у этих формул есть проблемы!)

# Как сравнить разбиения?




0.65




0.65

- $(5/6, 1/6)$  и  $(1/6, 5/6)$
- $0.65 + 0.65 = 1.3$



0.994



0

- $(6/11, 5/11)$  и  $(0, 1)$
- $0.994 + 0 = 0.994$


# Критерий информативности

$$Q(R, j, t) = H(R) - \frac{|R_\ell|}{|R|} H(R_\ell) - \frac{|R_r|}{|R|} H(R_r) \rightarrow \max_{j,t}$$


- Или так:

$$Q(R, j, t) = \frac{|R_\ell|}{|R|} H(R_\ell) + \frac{|R_r|}{|R|} H(R_r) \rightarrow \min_{j,t}$$

# Как сравнить разбиения?




0.65




0.65

$(5/6, 1/6)$  и  $(1/6, 5/6)$

$$0.5 * 0.65 + 0.5 * 0.65 = 0.65$$



0.994



0

•  $(6/11, 5/11)$  и  $(0, 1)$


$$\bullet \frac{11}{12} * 0.994 + \frac{1}{12} * 0 = 0.911$$




# А для регрессии?

10	1	2
12	0	11

# А для регрессии?



# А для регрессии?



# Задача регрессии

$$H(R) = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} (y_i - y_R)^2$$

$$y_R = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} y_i$$

- То есть «хаотичность» вершины можно измерять дисперсией ответов в ней

# **Жадное построение дерева**

# Как строить дерево?

- Оптимальный вариант: перебрать все возможные деревья, выбрать самое маленькое среди безошибочных
- Слишком долго

# Как строить дерево?

- Мы уже умеем выбрать лучший предикат для разбиения вершины
- Будем строить жадно
- Начнём с корня дерева, будем разбивать последовательно, пока не выполнится некоторый критерий останова

# Критерий останова

- Ограничить глубину
- Ограничить количество листьев
- Задать минимальное число объектов в вершине
- Задать минимальное уменьшение хаотичности при разбиении
- И так далее




# Жадный алгоритм

- Поместить в корень всю выборку:  $R_1 = X$
- Запустить построение из корня:  $\text{SplitNode}(1, R_1)$


# Жадный алгоритм

- $\text{SplitNode}(m, R_m)$
- Если выполнен критерий останова, то выход
- Ищем лучший предикат:  $j, t = \arg \min_{j, t} Q(R_m, j, t)$
- Разбиваем с его помощью объекты:  $R_\ell = \{(x, y) \in R_m \mid [x_j < t]\}$ ,  
 $R_r = \{(x, y) \in R_m \mid [x_j \geq t]\}$
- Повторяем для дочерних вершин:  $\text{SplitNode}(\ell, R_\ell)$  и  $\text{SplitNode}(r, R_r)$


# Обучение деревьев




# Признаки



# Разбиения по признаку 1




# Разбиения по признаку 1




$$\frac{3}{13}H(p_l) + \frac{10}{13}H(p_r) = 0.53$$

# Разбиения по признаку 1



$$\frac{4}{13}H(p_l) + \frac{9}{13}H(p_r) = 0.65$$


# Разбиения по признаку 1




$$\frac{5}{13}H(p_l) + \frac{8}{13}H(p_r) = 0.62$$




# Разбиения по признаку 1



# Разбиения по признаку 2



# Разбиения по признаку 2




$(4/9, 5/9)$   
 $H(p) = 0.69$

$(1, 0)$   
 $H(p) = 0$

$$\frac{4}{13}H(p_l) + \frac{9}{13}H(p_r) = 0.47$$

# Разбиения по признаку 2




$(4/6, 2/6)$   
 $H(p) = 0.64$

$(4/7, 3/7)$   
 $H(p) = 0.68$

$$\frac{7}{13}H(p_l) + \frac{6}{13}H(p_r) = 0.66$$

# Разбиения по признаку 2




$(1/2, 1/2)$   
 $H(p) = 0.69$

$(6/9, 3/9)$   
 $H(p) = 0.46$

$$\frac{9}{13}H(p_l) + \frac{4}{13}H(p_r) = 0.53$$

# Разбиения по признаку 2





$(4/9, 5/9)$   
 $H(p) = 0.69$

$(1, 0)$   
 $H(p) = 0$

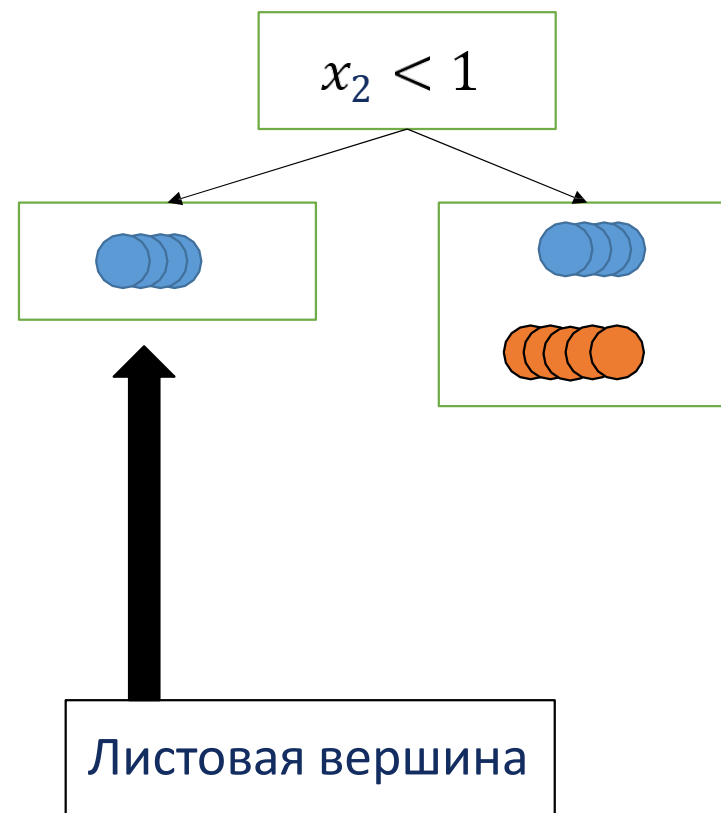

$$\frac{4}{13}H(p_l) + \frac{9}{13}H(p_r) = 0.47$$

Лучшее разбиение!

# Обучение деревьев





# Обучение деревьев

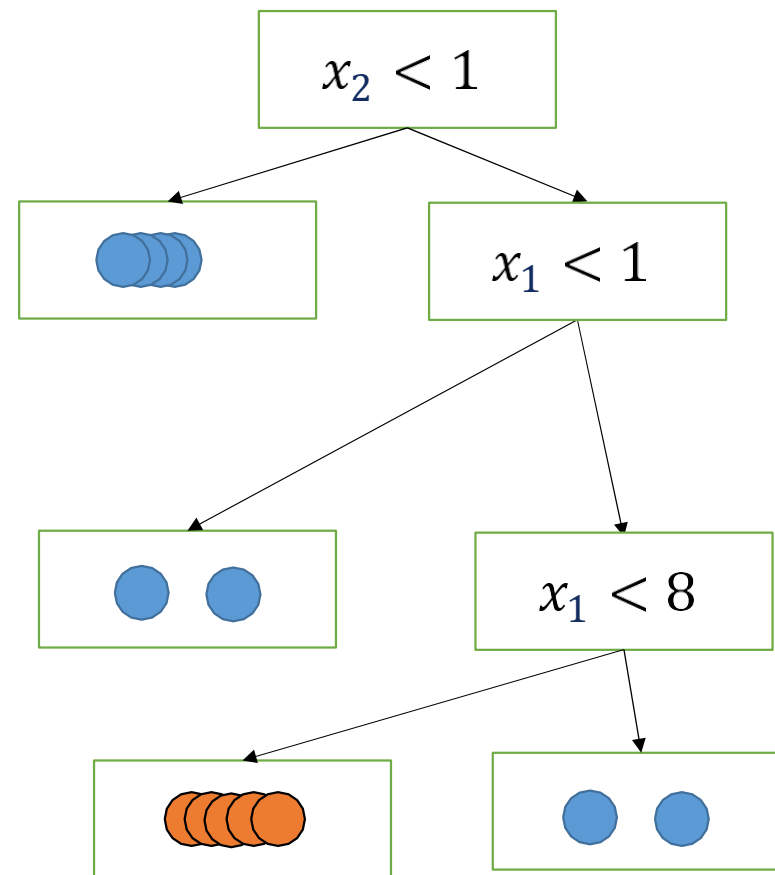





# Обучение деревьев



# Обучение деревьев



# Резюме

- Решающие деревья позволяют строить сложные модели, но есть риск переобучения
- Деревья строятся жадно, на каждом шаге вершина разбивается на две с помощью лучшего из предиктов
- Алгоритм довольно сложный и требует перебора всех предикатов на каждом шаге

# Спасибо за внимание!



**Ildar Safilo**

**@Ildar\_Saf**

**irsafilo@gmail.com**

**<https://www.linkedin.com/in/isafilo/>**